Reporte Tecnico: Modelos de Aprendizaje Automatico para Prediccion Clinica

Tareas: Respuesta Patologica Completa (pCR), Supervivencia Global (OS) y Supervivencia Libre de Enfermedad (DFS)

1. Datos y metodologia

Se usaron tres archivos: **train-data-pCR** (463 pacientes, 15.6 % pCR positiva), **survival-data-OS** (564 pacientes con desenlace conocido, 23.8 % de eventos) y **survival-data-DFS** (556 pacientes con desenlace conocido, 32.9 % de eventos). Las variables son clinicas y patologicas (estado menopausico, edad, cT, cN, histologia, grado, ER, PR, Ki67, HER2). En OS y DFS tambien se incluyen pCR, ypT y ypN como predictores; en la tarea pCR no se incluyen, porque se conocen despues de la cirugia. Los desenlaces OS y DFS ya venian codificados como 0/1 y no incluyen tiempo de seguimiento, por lo que se trataron como clasificacion binaria (no se ajustaron modelos de supervivencia con censura). Se eliminaron las filas con desenlace faltante (8 en OS, 16 en DFS).

Particion. 80 % entrenamiento / 20 % prueba, estratificada por clase (semilla 42): 93 pacientes de prueba en pCR (14 positivos), 113 en OS y 112 en DFS. Toda la seleccion y la validacion cruzada se hicieron solo sobre el 80 % de entrenamiento; el conjunto de prueba se uso una unica vez para reportar metricas.

Preprocesamiento (dentro de cada fold, sin fuga de datos). Imputacion (mediana / moda), estandarizacion de numericas y one-hot de categoricas.

Modelos (5). Regresion Logistica, Random Forest, SVM (kernel RBF), XGBoost (300 arboles, profundidad 3, tasa de aprendizaje 0.05) y Red Neuronal MLP (32-16). Los modelos con soporte usan *class_weight='balanced'*.

Umbral de decision. Con clases desbalanceadas, el umbral 0.5 hace que algunos modelos casi nunca predigan la clase positiva. Cada modelo elige su umbral maximizando F1 con predicciones out-of-fold dentro del entrenamiento. Accuracy, Precision, Recall y F1 dependen de ese umbral; AUC y Brier no.

Validacion cruzada y significancia. CV estratificada 5 folds x 5 repeticiones (25 remuestreos, mismos folds para todos los modelos) sobre el entrenamiento, con AUC por fold. Pruebas: Friedman global; t pareada corregida de Nadeau-Bengio (prueba principal, corrige la dependencia entre folds solapados); Wilcoxon pareado como contraste no parametrico; correccion de Holm por comparaciones multiples (4 comparaciones por tarea). Un modelo se considera significativamente mejor solo si su AUC medio es mayor **y** el p-valor de Holm < 0.05.

Criterio de seleccion del mejor modelo. Mayor AUC medio en validacion cruzada (prioridad clinica a la discriminacion), revisando F1 y Brier. No se eligio con el conjunto de prueba para no sesgar la estimacion final.

2. Resultados en el conjunto de prueba

Fila resaltada = mejor modelo segun AUC medio en validacion cruzada. 'AUC CV' es media +/- desviacion estandar de 25 folds.

pCR (Respuesta Patologica Completa)

Modelo	Accuracy	Precision	Recall	F1	AUC	Brier	Umbral	AUC CV
LogReg	**0.667**	**0.270**	**0.714**	**0.392**	**0.745**	**0.198**	**0.45**	**0.765+/-0.060**
RandomForest	0.785	0.385	0.714	0.500	0.778	0.132	0.36	0.687+/-0.049
SVM	0.688	0.273	0.643	0.383	0.731	0.117	0.18	0.723+/-0.058
XGBoost	0.570	0.229	0.786	0.355	0.706	0.132	0.05	0.658+/-0.051
MLP	0.656	0.125	0.214	0.158	0.528	0.155	0.36	0.661+/-0.065

OS (Supervivencia Global)

Modelo	Accuracy	Precision	Recall	F1	AUC	Brier	Umbral	AUC CV
LogReg	0.531	0.314	0.815	0.454	0.690	0.221	0.41	0.622+/-0.070
RandomForest	0.575	0.352	0.926	0.510	0.756	0.164	0.26	0.628+/-0.057
SVM	**0.637**	**0.365**	**0.704**	**0.481**	**0.707**	**0.167**	**0.24**	**0.642+/-0.063**
XGBoost	0.372	0.271	0.963	0.423	0.693	0.174	0.06	0.627+/-0.065
MLP	0.230	0.232	0.963	0.374	0.516	0.199	0.23	0.477+/-0.077

DFS (Supervivencia Libre de Enfermedad)

Modelo	Accuracy	Precision	Recall	F1	AUC	Brier	Umbral	AUC CV
LogReg	0.491	0.365	0.730	0.486	0.677	0.226	0.39	0.653+/-0.066
RandomForest	**0.598**	**0.438**	**0.757**	**0.554**	**0.665**	**0.213**	**0.33**	**0.679+/-0.058**
SVM	0.545	0.400	0.757	0.523	0.658	0.203	0.27	0.670+/-0.063
XGBoost	0.571	0.413	0.703	0.520	0.649	0.217	0.22	0.661+/-0.048
MLP	0.330	0.330	1.000	0.497	0.541	0.233	0.05	0.479+/-0.057

3. Significancia estadistica (mejor modelo vs. los demas, AUC en CV)

Dif. = AUC medio del mejor menos el del comparado. p(N-B) = t corregida de Nadeau-Bengio sin ajustar; p Holm = ajustado por comparaciones multiples. Los p-valores de Wilcoxon sobre 25 folds solapados son optimistas (anticonservadores) y se muestran solo como apoyo.

pCR (Respuesta Patologica Completa) - Friedman p = 1.06e-11

Mejor	vs.	Dif. AUC	p (N-B)	p Holm (N-B)	p Holm (Wilcoxon)	Signif.
LogReg	RandomForest	+0.078	0.0011	0.0034	0.0000	Si
LogReg	SVM	+0.042	0.0971	0.0971	0.0001	No
LogReg	XGBoost	+0.107	0.0003	0.0013	0.0000	Si
LogReg	MLP	+0.104	0.0136	0.0272	0.0000	Si

OS (Supervivencia Global) - Friedman p = 2.35e-10

Mejor	vs.	Dif. AUC	p (N-B)	p Holm (N-B)	p Holm (Wilcoxon)	Signif.
SVM	LogReg	+0.019	0.3623	1.0000	0.0574	No
SVM	RandomForest	+0.014	0.6006	1.0000	0.3127	No
SVM	XGBoost	+0.015	0.6308	1.0000	0.4908	No
SVM	MLP	+0.165	0.0015	0.0059	0.0000	Si

DFS (Supervivencia Libre de Enfermedad) - Friedman p = 7.97e-10

Mejor	vs.	Dif. AUC	p (N-B)	p Holm (N-B)	p Holm (Wilcoxon)	Signif.
RandomForest	LogReg	+0.025	0.3986	1.0000	0.0787	No
RandomForest	SVM	+0.009	0.5541	1.0000	0.1199	No
RandomForest	XGBoost	+0.017	0.3761	1.0000	0.0766	No
RandomForest	MLP	+0.199	0.0001	0.0004	0.0000	Si

4. Conclusiones

pCR - Mejor modelo: Regresion Logistica (AUC CV 0.765; AUC prueba 0.745; F1 prueba 0.392). Supera significativamente a Random Forest (p Holm = 0.0034), XGBoost (0.0013) y MLP (0.027), pero **no** a SVM (p Holm = 0.097; diferencia de 0.042 en AUC). Veredicto: superioridad significativa sobre 3 de 4 competidores, no sobre todos. Nota: en el conjunto de prueba Random Forest obtuvo mejor AUC (0.778) y F1 (0.500), pero esa muestra tiene solo 14 casos positivos y en CV Random Forest rinde 0.078 AUC menos, de modo que se prioriza la evidencia de CV.

OS - Mejor modelo: SVM (AUC CV 0.642; AUC prueba 0.707; F1 prueba 0.481). Solo supera significativamente a la red neuronal MLP (p Holm = 0.006). Frente a Regresion Logistica, Random Forest y XGBoost las diferencias (0.014 a 0.019 de AUC) **no son estadisticamente significativas** (p Holm = 1.0). Los cuatro modelos distintos del MLP son estadisticamente equivalentes; el AUC absoluto es modesto (0.62 a 0.64 en CV).

DFS - Mejor modelo: Random Forest (AUC CV 0.679; F1 CV 0.524; AUC prueba 0.665; F1 prueba 0.554, el mas alto). Solo supera significativamente al MLP (p Holm = 0.0004); contra Regresion Logistica, SVM y XGBoost no hay diferencia significativa (p Holm = 1.0).

Veredicto global. En ninguna de las tres tareas el modelo elegido supera con $p < 0.05$ a *todos* los demas. Se puede afirmar que es mejor que los modelos senalados arriba; frente al resto la evidencia indica empate estadistico, por lo que la eleccion se apoya ademas en parsimonia (la Regresion Logistica es la mas interpretable). La red neuronal MLP fue el peor modelo en OS y DFS (AUC en CV cercano a 0.5) y en pCR quedo entre los dos peores.

5. Limitaciones

(i) Muestras pequenas: conjuntos de prueba de 93 a 113 pacientes, con pocos eventos en pCR, por lo que las metricas de prueba tienen amplia incertidumbre y no deben usarse para elegir modelo. (ii) OS y DFS se modelaron como clasificacion binaria sin tiempo de seguimiento ni censura; no se uso analisis de supervivencia (Cox, RSF). (iii) Sin ajuste exhaustivo de hiperparametros (configuraciones fijas razonables). (iv) La MLP con tan pocos datos tiende a sobreajustar. (v) Sin validacion externa. (vi) En OS/DFS, ypT y ypN solo estan disponibles tras la cirugia; los modelos son pronosticos post-operatorios.

Reproducibilidad: *pipeline_clinico.py* (semilla 42) genera los CSV en *resultados/*; *make_report.py* construye este PDF.